


Tu setup de QA no se diseña: se cultiva

De prompt suelto a skills, rules y hooks.

Edgardo Crovetto · 2026

Una noche perdí 90 minutos

cazando flaky tests fantasma



Se pisaban entre sí, y nadie lo sabía. Todo **rojo**. Nada roto.

Hoy eso no puede volver a pasarme.

Y no es porque yo me acuerde: es porque mi setup se acuerda por mí.

Esta charla es la historia de cómo llegué ahí.

■ Quién soy

Edgardo Crovetto · Senior QA automation engineer

Java + TypeScript · tests automatizados · CI/CD · pipelines

Me gusta mejorar procesos — sobre todo los que ya estaban funcionando.

“ Esta charla no es sobre features. Es sobre **un patrón que se repite** — y lo que hacés con eso. ”

[linkedin.com/in/edgardocrovetto](https://www.linkedin.com/in/edgardocrovetto)

■ La pregunta de hoy

“ ¿Puedo automatizar mi proceso de QA con IA?

”

Spoiler: sí — **sobre las bases que ya tenés.**




■ Mi setup antes de IA

Plataforma de streaming · servicio backend REST

Framework: Java + TestNG + RestAssured + Allure reports + Jira + TestRail + Jenkins

Pipeline diario:



“ Funcionaba. Pero todo el conocimiento de cada ticket vivía **en mi cabeza.**

”

■ Tu día como QA, hoy

- **Análisis del ticket** — Jira + repo + Confluence (AC) + TestRail · nada de eso queda escrito en un solo lugar
- **Mapeo AC ↔ cambio** — comparás docs vs branch a ojo, página por página
- **Test cases + automation** — copiás AC a TestRail, traducís a TestNG/RestAssured, linkeás IDs a mano
- **Ejecución multi-env** — Jenkins contra 3 ambientes · comparás resultados · investigás cada **rojo**
- **PR review** — armás la evidencia, pingeás 2 peers, esperás, re-pingeás
- **Bug encontrado** — abrís ticket, pegás logs, follow-up del ciclo de vida en Jira
- **Mañana** — sesión nueva. Re-explicás el ticket, el plan, las convenciones.

Mucho de eso es conocimiento que se pierde entre sesiones.

¿Y si ese conocimiento sobreviviera?

La tesis
Mi setup no se diseña.
Se cultiva.

■ Mis primeros pasos con Claude

1. Conectar Claude al repo del trabajo

- Todo arrancó con un `CLAUDE.md` de apenas 5 líneas — se lo pedís en la conversación, no lo escribís a mano
- Lo demás vino con el tiempo

2. Agregar MCPs, uno a uno


Jira, TestRail, Jenkins, GitHub, Confluence — el detalle, enseguida.

A partir de ahí: **prompts del día a día.**

No hubo plan. Aparecieron patrones.



■ Cómo Claude conoce mi proyecto



Todo es **texto plano en disco**. Versionado. Reviewable.

■ MCPs — los puentes a sistemas externos

Memory, skills, rules y hooks viven en tu repo.

El trabajo real cruza varios sistemas. Los MCPs los conectan.

Conectar uno también se pide en conversación — no hay instalador que armar a mano.


MCP	PARA QUÉ LO USO
 Jira	Leer ticket + AC, comentar, transicionar el estado
 TestRail	Leer/escribir test cases, asociar runs a builds
 Jenkins	Triggerear builds, leer resultados, descargar logs
 GitHub	Leer el PR y su diff, postear el review, ver los checks
 Confluence	Leer specs y acceptance criteria

Una sola conversación con Claude puede pasar por los **5**.

El review de la Demo 4 se postea por acá.

■ La pirámide de promoción

Una sola historia: el typecheck que me olvidaba después de cada rebase, subiendo un nivel cada vez que el anterior no alcanzó.




Saltea la Rule — y no es olvido: una rule me lo *recuerda*, y el problema era justamente que recordármelo no alcanzaba. **Pocas piezas llegan hasta arriba**: no es una escalera que subís entera, es un menú. La Rule tiene su propia cicatriz — `no-parallel-ci`, los 90 minutos del principio.

“ Ninguna pieza se diseñó. Cada una fue admitir que acordarse no escala. ”

■ Un skill no siempre ejecuta: a veces delega


`multi-agent-pr-review` es un `SKILL.md` como cualquier otro — markdown en tu repo, la misma pirámide. Lo distinto es lo que hace adentro: en vez de correr pasos él mismo, **despacha subagentes**. Cada uno con su propio contexto: no ve tu historial, y al principal solo le vuelve el resumen.



Antes de que un peer humano vea el PR, ya pasó por 5 revisores especializados, cada uno cazando su propia clase de bug. Al peer le queda lo que un especialista de tipos no puede ver: arquitectura. *(Mis compañeros aplaudieron esto.)*

Lo que no cambia: quien aprueba sigue siendo responsable de lo que aprueba.

■ El flujo end-to-end



rules y memory importadas: siempre cargadas · el registry se lee cuando hace falta

🔄 corrección repetida 3× → writing-skills → skill nueva

Cada pieza compone con las demás. No hay un workflow único — hay piezas.

Ahora, en vivo

Un día de QA, del ticket al merge

6 escenas a lo largo de una jornada de 8 horas · repo `claude-qa-demo`



todo offline · cada escena deja algo para la siguiente

El demo está en TypeScript para que entre en pantalla y compile rápido.

*El patrón es **idéntico** en Java/TestNG/RestAssured.*

■ Demo 1 · 9:00 — Ticket → plan de cobertura

|“ ↔ *Resuelve: las 4 pestañas para armar el panorama completo.* ”

Input: un ticket de Jira mockeado en `mocks/jira/DEMO-100.json` .

Prompt:

|“ *"Planificá el trabajo para DEMO-100."* ”

Skill invocada: `ticket-coverage-gap-analysis`

Output:

- Mapa de cobertura existente (tabla)
- Gaps identificados (✅ / ⚠️ / ❌)
- TodoWrite con casos propuestos + estimación

El plan queda con un ❌: slug malformado sin cubrir. →

■ Demo 2 · 10:00 — TDD asistido

|“ ↔ Resuelve: saltar el "red" y aterrizar directo en código sin test que lo respalde. ”

Demo 1 dejó un ✖: **DEMO-100** pide que un slug malformado sea rechazado.
Hoy `getChannelBySlug('News Channel!')` devuelve `null`, como si no existiera.

Prompt:

|“ "Cerraré ese gap con TDD." ”

Skill invocada: `superpowers:test-driven-development`
(descargada del marketplace, no la escribí yo)

1. Test que espera el rechazo → red
2. Validación mínima del formato → green
3. Refactor opcional

El skill guía el orden — y hoy lo respetó.

Gap cerrado, tests verdes. Ahora quiero correr esto en CI. →

■ Demo 3 · 11:30 — Gate local antes de CI

“ ↵ Resuelve: pushear un cambio con un typo y enterarte 10 minutos después, cuando Jenkins ya arrancó el build. ”

Prompt:

“ "Triggeá un build de Jenkins para esta branch." ”

Lo que pasa en vivo:

1. `local-build-gate` → typecheck + tests locales ✓
2. `no-parallel-ci.mdc` → **build 43 ya está corriendo en stage** (`build-43-running.json`)
3. Claude **se niega a triggerear**: esperar ~12 min o cambiar de env

El guardrail no me cuida a mí del agente — nos cuida a los dos del incidente.

Los 90 minutos del principio, exactamente.

Build 43 termina, corre el mío, abro el PR. →

■ Demo 4 (1/2) · 14:00 — Multi-agent PR review ★

|“ ↵ *Resuelve: repetir los mismos comentarios review tras review.*”

PR sembrado con 5 bugs distintos (`mocks/github/pr-7.diff`):

- `silent-failure-hunter` → `catch (e) { return [] }` se traga errores
- `type-design-analyzer` → `as Channel` miente
- `comment-analyzer` → comentario que dice "sorted" pero no ordena
- `pr-test-analyzer` → test que solo verifica `toBeDefined()`
- `code-reviewer` → `// TODO` en producción

Dispatch: 5 agentes en paralelo, **un solo mensaje.**

■ Demo 4 (2/2) — el resultado agregado

claude · comentó en #7 · hace 1 minuto

Review summary

BLOCKERS silent-failure-hunter · 1

SUGGESTIONS type-design-analyzer · 1 comment-analyzer · 1 pr-test-analyzer · 1

NITPICKS code-reviewer · 1

► [Per-axis details](#)

5× paralelo, contexto aislado, 1 comentario al final.

Lo leo entero antes de postearlo. Si alguien pregunta por qué se bloqueó el PR, la respuesta soy yo — "no sé, lo hizo la IA" no es una respuesta.

■ ¿Y esto no lo hacía ya un linter?

Buena parte sí — y **el linter no se saca**: es más barato y no se cansa.

SonarQube marca ese `catch` que ignora la excepción (`S2486`). Lo que no ve es que el comentario dice *"sorted"* sobre código que no ordena, ni que un `toBeDefined()` no prueba nada.

El linter matchea patrones. El subagente lee. Van juntos.

Review adentro. Antes del merge, la regression completa en Jenkins. →

■ Demo 5 · 15:00 — Triage de fallas de CI

|“ ↵ Resuelve: triagear tests **rojos** a mano contra known-issues.

”

Input: `mocks/jenkins/build-44.json` — 5 **rojos** sin etiquetar: nombre, mensaje, stack y los commits. Y es **la misma branch de hoy:**

`feature/DEM0-100-channels-coverage` .

Skill invocada: `ci-failure-triage` + registry `memory/known-issues.md`

CATEGORÍA	DE DÓNDE SALE
Flaky test conocido	La firma matchea el registry (2× <code>Test timed out in 5000ms</code> , visto hasta build 39)
Infra	El ambiente no responde (<code>ECONNREFUSED</code> a auth)
Regresión real	No está en el registry y el commit toca código relacionado

La categoría se deduce de la evidencia — no viene dada en el JSON.

■ El triage no termina en la categoría

Son 5 fallas para que entren en pantalla. En un build de cientos, el mismo skill lee los **logs completos**, agrupa las fallas relacionadas entre sí y te dice **por dónde empezar a mirar** — no solo "esto es un flaky test".



Triage hecho. Pero hoy, tres veces, me corregiste lo mismo... →

■ Demo 6 · 16:00 — De prompt repetido a skill ✨

“ ↩ *Resuelve: re-explicar el ticket, el plan, las convenciones en una sesión nueva.* ”

Durante la sesión, Claude fue corregido **3 veces** con
"acordate de chequear X antes de Y".

Prompt:

“ *"Esto ya te lo repetí 3 veces. ¿Lo convertimos en skill?"* ”

Skill invocada: `superpowers:writing-skills`
(alternativa del marketplace: el plugin `skill-creator`)

Output: un `SKILL.md` nuevo en `.claude/skills/`.

La slide del principio terminaba:

"Mañana — sesión nueva. Re-explicás el ticket, el plan, las convenciones."

**Mañana — sesión nueva. No se re-explica ni el ticket,
ni el plan, ni las convenciones.**

Este es el patrón completo en acción.

■ Y no siempre tenés que contar vos

Hoy lo repetí 3 veces y lo noté. Cuando no lo notás, se lo preguntás:

“Revisá las últimas conversaciones y decime qué skills hay que crear o actualizar.”



El patrón es el mismo — cambia quién lo detecta.

■ Mi línea de tiempo real

semana 1	● BASE	CLAUDE.md inicial: 5 líneas — nombre, comando de test, convención de commits
semana 1	● MEMORY	feedback-local-build-before-ci — "acordate del typecheck", anotado. Y me lo olvidé igual
semana 1	● SKILL	local-build-gate — CI roto 2 veces por un typo que typecheck cazaba en 2 seg
semana 3	● RULE	no-parallel-ci — los 90 minutos cazando flaky tests fantasma en stage
semana 3	● RULE	english-only — un compañero no podía revisar un commit en español
semana 6	● SKILL	ci-failure-triage — las mismas 3 preguntas cada lunes
semana 6	● SKILL	known-issues-registry-update — perdía el registro de qué flaky test ya vi
semana 9	● SKILL	multi-agent-pr-review + plugin pr-review-toolkit — de secuencial a paralelo
semana 11	● HOOK	typecheck-after-edit — memory + skill no alcanzaban
semana 13	● SKILL	ticket-coverage-gap-analysis — la misma conversación 4 sprints seguidos
semana 16	● MEMORY	known-issues — el registry crece con cada flaky test: se lee cuando hace falta
ahora	●	El setup quedó versionado en el repo — los compañeros lo mejoran con sus propias PRs
futuro	○	Nuevas ideas, nuevas necesidades — seguimos buscando patrones

Nada se planificó. Cada pieza respondió a un dolor concreto.

■ El agente también construye

Cultivar no es solo skills, rules y memory **para** el agente.

Es lo que el agente construye **con vos**:

- **CI a tu medida** — el pipeline corre con tus reglas, no con las heredadas
- **Linters / checkstyle / SonarQube** — configurados y explicados, no copiados de un gist
- **Coverage y notificaciones** — Allure, dashboards, el build roto te encuentra a vos

El hook de typecheck que viste hace rato **es exactamente este patrón** — aplicado a un linter o a un quality gate, la conversación es la misma.

“ **No le tengas miedo a lo desconocido: el costo de aprender colapsó.**

Cultivás al agente — y el proyecto queda mejor armado que antes.

”

■ Qué le toca a la persona

	EL AGENTE	VOS
Ejecución	Corre el procedimiento, agrega resultados, propone cambios de código para revisar	—
Criterio	—	Interpretás un AC ambiguo, decidís qué es "suficiente"
Aporte	—	Metés lo que el agente no vio: charlas, discusiones, decisiones de negocio — enriquecés, corregís
Revisión	Hace el primer pase (5 subagentes en paralelo)	Leés el resultado antes de postearlo o mergear
Decisión	—	Aprobás, bloqueás, o decidís qué se promueve a skill/rule
Responsabilidad	—	Si preguntan por qué, la respuesta sos vos

El agente ejecuta. La persona aporta lo que falta, decide, revisa y responde por el resultado — eso no se delega.

Mismo criterio que en la Demo 4: se lee entero antes de postearlo — "no sé, lo hizo la IA" no es una respuesta válida.

La pregunta del principio

¿Puedo automatizar mi proceso de QA con IA?

Sí — lo acabás de ver.

¿Se diseña? No. Se cultiva.

■ 4 pasos para el lunes

1. Un `CLAUDE.md` de 5 líneas en el repo donde más trabajás.

Nombre del proyecto, comando de test, convención de commits. Nada más.

2. Probá hacer todo con el agente, aunque hoy lo hagas por fuera.

Leer el ticket de Jira, estudiar la story, compararla contra el código.

Ahí empiezan a aparecer los patrones repetibles.

3. Anotá la próxima corrección que repitas.

La segunda vez que escribís *"acordate de X antes de Y"*, eso es una memory.

La tercera, un skill.

4. Bajá lo que ya existe: `/plugin marketplace add` y después `/plugin install` → `superpowers` + `pr-review-toolkit`.

Arrancás con workflows que no tuviste que escribir. Son públicos: usá los de confianza, los que tu organización ya aceptó.

“ Nada de esto necesita presupuesto, permiso, ni una reunión de arquitectura. ”

Tu setup no se diseña. Se cultiva.

Memory + Skills + Rules + Hooks = workflow reproducible

Cultivarlo no te saca del medio: el criterio, el dominio y la firma siguen siendo tuyos.

¿Preguntas?

github.com/edcrove/claude-qa-demo

linkedin.com/in/edgardocrovetto

Apéndice

Anatomía y ejemplo real de cada pieza

Memory · Skill · Rule · Hook

■ Memory — anatomía

Una corrección repetida **2 veces** es candidata a memory.

Prompt:

“ *"Guardá esto en memory: <la corrección o el hecho>."* ”

```
---
name: kebab-case-slug
description: <One-line summary; Claude lo usa para decidir si traer este recuerdo>
metadata:
  type: feedback | user | project | reference
---

<Body: el hecho, la preferencia, la corrección>

**Why:** <razón concreta – usualmente un incidente pasado>
**How to apply:** <cuándo aplica>
```

Ese prompt es lo único que hace falta — Claude arma el archivo. Persiste entre sesiones. Sobrevive al `/clear`.

■ Memory — ejemplo real

Prompt:

“ *"Guardá esto en memory: corré typecheck y tests locales antes de cualquier build remoto. Me olvidé 2 veces después de un rebase."* ”

```
---
name: feedback-local-build-before-ci
description: Always run local typecheck + tests before triggering remote CI
metadata:
  type: feedback
---

Run `npm run typecheck && npm test` before any remote CI build.

**Why:** failed CI runs burn ~10 minutes per attempt.
**How to apply:** see `local-build-gate` skill.
```

Nació después de olvidarme el `typecheck` post-rebase un lunes a la mañana.

■ Skill — anatomía

Prompt:

“ *"Convertí esto en un skill."* ”

```
---
name: kebab-case-name
description: Use when <trigger>. <One-sentence summary.>
---

# Title

## When to use
- Concrete trigger 1
- Concrete trigger 2

## Steps
1. Concrete and verifiable
2. ...

## Output
What the skill produces.
```

description es el campo crítico: Claude lo usa para decidir si invocar.

■ Skill — ejemplo real

Prompt:

“ *"Rompi el build dos veces esta semana por lo mismo. Convertí el chequeo local en un skill."* ”

```
---
name: local-build-gate
description: Use before triggering remote CI to fail fast on
  compile or unit-test errors. Saves ~10 min per broken push.
---

# Local build gate

1. **Typecheck:** cd demo-app && npm run typecheck
2. **Unit tests:** cd demo-app && npm test
3. **Smoke check:** call the endpoint once

## When to skip
Never. Compose with `no-parallel-ci.mdc`.
```

Nació después de romper el build dos veces en la misma semana.

■ Rule — anatomía

Prompt:

“ *"Convertí esto en una rule — quiero que esté siempre presente."* ”

```
---  
description: One-line summary, ≤ 120 chars, present tense  
---
```

Rule statement: what you must / must not do.

****Why:**** the reason — often a past incident.

****How to apply:**** when this kicks in.

A diferencia de un skill, **siempre está cargada** — pero no por ser una rule: lo está porque `CLAUDE.md` la **importa** con `@`. Sin ese import, el archivo no hace nada, y su `description` —a diferencia de la de un skill— no la lee nadie.

■ Rule — ejemplo real

Prompt:

“ *"Esto no puede volver a pasar. Regla: nunca triggerear un build si ya hay otro corriendo en el mismo ambiente."* ”

```
---  
description: Never trigger two CI builds in parallel against  
  the same TEST_ENV – they share credentials.  
---  
  
Before triggering a CI build:  
1. Check whether another build is already running on the env.  
2. If yes, wait or pick a different env. Do not queue parallel.  
  
**Why:** parallel runs share credentials → mutual interference  
that looks like real regressions but isn't.
```

Nació después de 90 minutos cazando flaky tests fantasma.

■ Hook — anatomía

Prompt:

“ *Convertí esto en un hook — que corra solo, sin que nadie lo invoque.* ”

```
{
  "hooks": {
    "PostToolUse": [{
      "matcher": "Edit|Write|MultiEdit",
      "hooks": [{
        "type": "command",
        "command": "<bash command>"
      }]
    }]
  }
}
```

Se engancha a momentos del ciclo: antes (**PreToolUse**) y después (**PostToolUse**) de cada tool, cierre de sesión (**Stop**), entre otros.

El comando recibe el evento como **JSON por stdin**.

No depende del modelo: lo dispara el runtime de Claude Code y siempre se ejecuta.

■ Hook — ejemplo real

Prompt:

“ *"Me olvidé el typecheck 5 veces seguidas — teniendo memory y skill. Convertilo en hook: que corra en cada edit, pase lo que pase."* ”

```
{
  "hooks": {
    "PostToolUse": [{
      "matcher": "Edit|Write|MultiEdit",
      "hooks": [{
        "type": "command",
        "command": "f=$(jq -r '.tool_input.file_path // empty');
                    case \"$f\" in \"$CLAUDE_PROJECT_DIR\"/*.*ts)
                      cd \"$CLAUDE_PROJECT_DIR/demo-app\" && npm run typecheck;;
                    esac"
      }]
    }]
  }
}
```

El path sale del JSON de stdin con `jq` — no de una variable de entorno.

Nació después de olvidarme el `typecheck` 5 veces seguidas — **teniendo el memory y el skill**. El hook fue el final del camino.

Backup — Q&A

Respuestas que suelen hacer falta

■ ¿Y los costos en tokens?

- El día a día corre en un modelo mid-tier; el multi-agent review es el único paso caro
- 5 subagentes = 5 contextos aislados — pagás tokens para **no** pagar contexto contaminado
- El costo contra el que se compara: 10 min de CI roto · 90 min de flaky tests fantasma · un review que espera 2 días
- **Lo siempre-cargado es lo único con costo recurrente:** memory y rules se pagan en cada mensaje, de cada sesión. Una skill cuesta su `description` siempre y su cuerpo sólo cuando se usa; un hook no consume contexto. Por eso las skills viven afuera hasta que hacen falta

■ ¿Qué pasa cuando cambia el modelo?

- Los **prompts** afinados a un modelo a veces mueren con él
- **Skills, rules y memory sobreviven** — describen tu proceso, no al modelo
- El **hook** ni siquiera pasa por el modelo: lo ejecuta el runtime
- Por eso la pirámide promociona hacia arriba: **cada nivel es más robusto al cambio**

■ ¿Funciona offline? ¿Sirve en mi stack?

- Este demo corre **100% offline**: mocks JSON en disco, cero credenciales
- Solo los **MCPs** reales (Jira, TestRail, Jenkins, GitHub, Confluence) necesitan red
- El patrón no sabe de lenguajes: idéntico en **Java/TestNG/RestAssured**
- Todo es texto plano: clonalo y reemplazá los mocks por tus sistemas

■ ¿Quién audita al clasificador de CI?

- `ci-failure-triage` no decide a ciegas: la categoría sale de evidencia visible (firma en el registry, stack, commits) — no es una caja negra
- El registry (`memory/known-issues.md`) lo propone el agente y lo confirmás vos antes de commitear, y pide **2+ sightings** — un solo fallo nunca es un flaky test
- Si la categoría no cierra con evidencia, **regresión real es el default** — el skill sesga hacia flaggear de más, no de menos
- Igual que en la Demo 4: el agente propone la categoría, vos la confirmás antes de actuar